GPT와 LLM

Generative Pre-trained Transformer

대규모 언어 모델의 시대

이종혁 (경희대학교 미디어학과)

BERT vs GPT — 이해 vs 생성

	BERT	GPT
기반 구조	Transformer 인코더	Transformer 디코더
방향성	양방향 (Bidirectional)	단방향 (Left-to-Right)
학습 방식	MLM (빈칸 채우기) + NSP	Next Token Prediction (다음 단어 예측)
강점	언어 이해 (분류, NER, QA)	언어 생성 (대화, 요약, 번역)
약점	텍스트 생성에 부적합	양방향 문맥 이해 제한적
활용 예	감정 분석, 검색 엔진, NER	ChatGPT, 글쓰기, 코드 생성
비유	독해 시험에 능한 학생	작문 시험에 능한 학생

BERT: "나는 이 문장을 이해할 수 있다" (이해) | GPT: "나는 다음 문장을 생성할 수 있다" (생성)

GPT — 다음 단어를 예측하는 생성 모델

GPT = Generative Pre-trained Transformer

Transformer의 디코더만 사용하는 대규모 언어 모델(LLM). 핵심 원리는 Next Token Prediction — 주어진 텍스트 다음에 올 단어를 예측. "나는 오늘 학교에" → "갔다" (가장 확률 높은 다음 단어를 생성). 이 과정을 반복하면 문장, 문단, 글 전체를 생성할 수 있음.

1 BERT와의 핵심 차이

BERT: 인코더 → 양방향 이해
"나는 [MASK]에 간다" → 빈칸 채우기
좌우 문맥 모두 참조

GPT: 디코더 → 단방향 생성
"나는 오늘" → "학교에" → "갔다"
왼쪽에서 오른쪽으로만 생성

2 왜 GPT가 대세가 되었나?

스케일링 법칙: 모델과 데이터가 커지면 성능이 향상됨

범용성: 번역, 요약, 코딩, 추론 등 다양한 과제 수행

창발적 능력(Emergent Abilities): 일정 규모 이상에서 예상치 못한 새로운 능력이 나타남

GPT의 발전 — GPT-1에서 GPT-4까지

모델	연도	파라미터	핵심 특징	학습 방식
GPT-1	2018	1.17억	Transformer 디코더 기반 최초 모델 사전학습 + 파인 튜닝 패러다임 제시	비지도 사전학습 + 지도 파인 튜닝
GPT-2	2019	15억	파인 튜닝 없이도 다양한 과제 수행 가능 "너무 위험해서 공개 못 한다" 화제	비지도 학습 다중 작업 학습
GPT-3	2020	1,750억	Few-shot Learning: 예시 몇 개만으로 학습 In-context Learning 능력 발현	비지도 학습 Few-shot Learning
InstructGPT	2022	~1,750억	지시-응답 데이터셋 학습 RLHF(인간 피드백 강화학습) 도입	지시-응답 학습 + RLHF
ChatGPT	2022	GPT-3.5	대화형 최적화 모델 일반 대중에게 AI 대중화의 기폭제	GPT-3.5 + InstructGPT 방식
GPT-4	2023	~1.7조(추정)	멀티모달(텍스트+이미지 입력) 추론 능력 대폭 향상, 시험 통과 수준	대규모 학습 + RLHF 고도화

핵심 흐름: 비지도 학습(GPT-1~3) → 지시-응답 학습(InstructGPT) → RLHF(ChatGPT) → 멀티모달(GPT-4) → 추론 강화(o1, o3)

In-context Learning과 Few-shot Learning

1 Zero-shot Learning

예시 없이 지시만으로 과제 수행

프롬프트:

"다음 문장의 감정을 분류하시오.

문장: 오늘 날씨가 정말 좋다"

→ 모델이 학습 없이 바로 "긍정" 출력

2 Few-shot Learning

소수의 예시를 프롬프트에 제공

프롬프트:

" 이 영화 최고! → 긍정, 너무 재미없다 → 부정

문장: 오늘 날씨가 정말 좋다 → ?“

→ 예시 패턴을 보고 "긍정" 출력

파인 튜닝 없이 프롬프트만으로 학습

3 In-context Learning

Zero-shot과 Few-shot을 포괄하는 개념

프롬프트 안 맥락(context)으로 과제를 이해하고 수행하는 능력

모델의 가중치는 변하지 않음 → 별도 학습 없이 추론에만 동작

4 왜 가능한가?

대규모 사전학습 덕분

수천억 개의 파라미터가 인터넷의 방대한 패턴을 학습

프롬프트가 주어지면 학습된 패턴 중 가장 적합한 것을 활성화

비유: 다양한 경험을 가진 전문가가 새로운 상황에서도 유추하여 대응

IGPT 활용과 조정 - Prompt Engineering, RAG, Fine-tuning

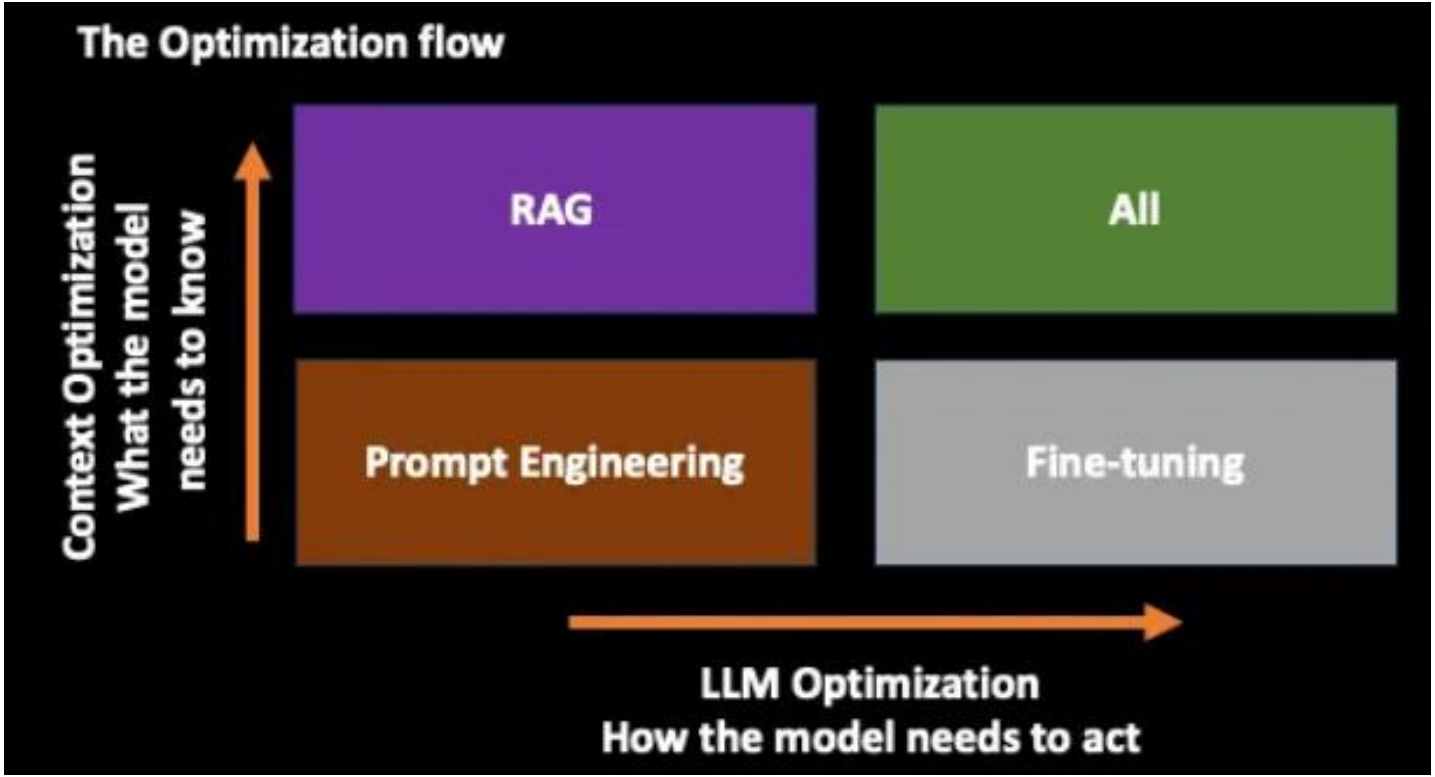

Prompt Engineering

언어 모델을 효율적으로 사용하기 위해 목표에 맞는 입력 텍스트(프롬프트)를 설계하는 기술. 같은 모델이라도 프롬프트에 따라 결과 품질이 크게 달라짐.

•페르소나 부여: 역할 기반 응답

당신은 뉴스 분석 전문가입니다.
아래 뉴스 기사에 등장하는 정보원을 추출하시오.
뉴스 기사: 실제 기사

•예시 제공(Few-shot): 형식과 스타일 학습

다음은 정보원 추출의 예입니다:
예시 기사:
환경부는 국내 미세먼지 농도가 개선되고 있다고 발표했다.
하지만 환경단체 그린피스는 "정부의 발표가 과장되었다"며
"독립적인 검증이 필요하다"고 강조했다.
예시 결과: [환경부, 그린피스]
아래 뉴스 기사에 등장하는 정보원을 추출하시오.
뉴스 기사: 실제기사

•배경-맥락-조건-제한 설명: 작업 이해도 증가

정보원은 기사 내용의 전달자이며, 기사에서 실명이나 익명으로
출처가 표시되어 드러납니다.
아래 뉴스 기사에 등장하는 정보원을 추출하시오.
뉴스 기사: 실제 기사

•논리적 추론 유도(CoT): 복잡한 문제 해결

뉴스 기사에서 정보원을 추출하고, 각 정보원의 유형을 분류하시오.
뉴스 기사: 실제기사
단계:
1. 주요 발언을 확인하세요.
2. 발언의 정보원를 추출하세요.
3. 정보원의 유형을 [공식, 비공식, 익명] 가운데 하나로 분류해.

*** 출력 형식 지정:** JSON, list 등 원하는 형식 명시. 후처리 용이

RAG (Retrieval Augmented Generation)

LLM의 근본적 한계: 학습 데이터에 없는 최신 정보나 특정 도메인 지식을 제공하기 어려움.

할루시네이션(Hallucination): 모르는 것도 자신 있게 답변하는 문제.

RAG: 외부 데이터 소스를 검색(Retrieval)하여 생성(Generation)에 활용하는 프레임워크.

RAG 파이프라인 (LangChain 기반)

1. **문서 적재 (Load)** → PDF, 웹, DB 등에서 원본 데이터 로드
2. **문서 분할 (Split)** → 긴 문서를 작은 청크(chunk)로 분할
3. **임베딩 (Embedding)** → 각 청크를 벡터로 변환 (수치화)
4. **벡터 저장 (Vector Store)** → 벡터 DB에 저장 (Chroma, FAISS 등)
5. **검색 (Retrieval)** → 질문과 유사한 청크를 검색
6. **생성 (Generation)** → 검색 결과 + 질문을 LLM에 전달하여 답변

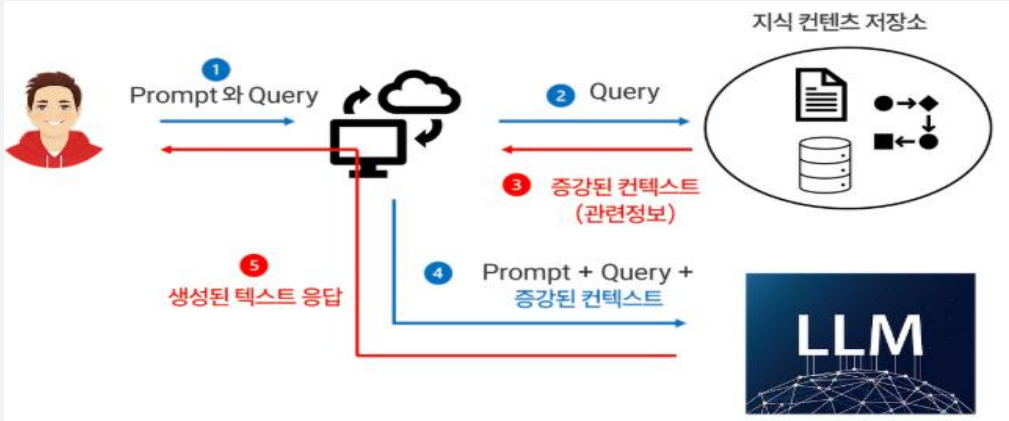

활용 예: 금융 자문 → 실시간 주가/경제 보고서 참조
의료 챗봇 → 최신 논문/건강 지침 참조
뉴스 분석 → 최신 기사 데이터 참조

Fine tuning - PEFT와 LoRA

PEFT = Parameter Efficient Fine Tuning. 사전학습된 LLM의 대부분 파라미터를 고정(freezing)하고 일부만 조정하여,
적은 컴퓨팅 자원으로도 특정 도메인에 우수한 성능의 모델을 만드는 방법. 전체 파인 튜닝은 수백~수천 GB GPU 메모리 필요

1 LoRA (Low-Rank Adaptation)

가장 널리 쓰이는 PEFT 기법

원리:

- 전체 가중치 행렬(W)을 직접 수정하지 않고
- 두 개의 작은 저랭크 행렬(A, B)을 추가
- W' = W + A*B (A: 작은 행렬, B: 작은 행렬)

장점:

- 훈련 파라미터 수 대폭 감소 (1% 이하)
- GPU 메모리 절감
- 원래 모델 성능 유지

2 PEFT의 장점과 활용

필요한 계산량 감소: 모델 크기를 줄이고 중복 파라미터 제거

추론 속도 향상: 모델이 작아져 빠르게 실행

비용 절감:

- API 사용 없이 자체 모델 활용
- 오픈소스 LLM + LoRA = 비용 효율적

Hugging Face에서 PEFT 모델 공유:

- huggingface.co/models?library=peft

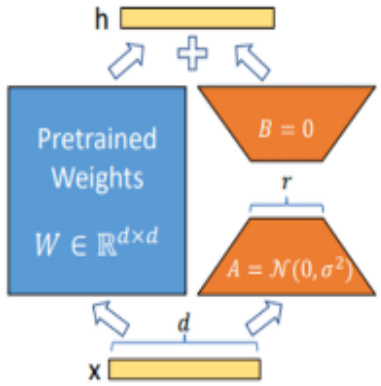

Figure 1: Our reparametrization. We only train A and B.

LLM 활용과 조정 — 3가지 접근법 비교

	프롬프트 엔지니어링	RAG	Fine-tuning (PEFT)
난이도	쉬움	중간	어려움
비용	최소 (API 비용만)	중간 (벡터DB + API)	높음 (GPU 필요)
최신 정보	불가 (학습 데이터 한정)	가능 (외부 검색)	학습 데이터 갱신 필요
도메인 특화	제한적	문서 기반 가능	가장 강력
모델 변경	없음 (프롬프트만 변경)	없음 (외부 지식 추가)	있음 (가중치 조정)
적용 사례	빠른 프로토타입, 간단한 과제	최신 정보 필요, 문서 기반 QA	도메인 전문 모델, 특수 작업 최적화

> 실무 권장 순서: 프롬프트 엔지니어링 먼저 시도 → 부족하면 RAG 추가 → 그래도 부족하면 Fine-tuning (humanloop.com/blog/optimizing-llms)

오픈소스 LLM — 공개된 대규모 언어 모델

왜 오픈소스 LLM이 중요한가? 상용 API(OpenAI, Anthropic)의 비용/보안/종속성 문제 → 자체 서버에서 운영 가능한 공개 모델 수요 증가. 기업/기관/연구기관이 자체 데이터로 파인 튜닝하여 특화 모델 개발 가능.

모델	개발사	파라미터	특징
LLaMA 3	Meta	8B ~ 405B	가장 활발한 오픈소스 생태계, 다양한 파인 튜닝 버전
Mistral / Mixtral	Mistral AI	7B ~ 8x22B	MoE(Mixture of Experts) 구조, 효율적 추론
Gemma	Google	2B ~ 27B	경량 모델, 모바일/엣지 배포 가능
Qwen	Alibaba	1.8B ~ 110B	다국어 지원 강화, 코드 생성 우수
EXAONE	LG	다양	한국어 성능 우수, 한국 기업 개발
Solar	Upstage	10.7B	한국어 특화, DPU(Depth Up-Scaling) 기법

성능 평가: huggingface.co/spaces/open-llm-leaderboard/open_llm_leaderboard

LLM 성능 평가 — Open LLM Leaderboard

주요 평가 기준 (Hugging Face Open LLM Leaderboard)

벤치마크	평가 내용	측정 능력
IFEval	Instruction-Following Evaluation	지시 따르기 능력 (프롬프트 준수)
BBH	Big-Bench Hard	다양한 고난도 NLP 과제 종합 평가
MATH	수학 문제 해결	수식 추론 및 계산 능력
GPQA	대학원 수준 물리 문제	전문 지식 및 과학적 추론
MUSR	다국어 이해 및 추론	언어 간 이해와 추론 전이 능력
MMLU	57개 분야 대학 수준 질문	광범위한 지식과 이해력

영어: huggingface.co/spaces/open-llm-leaderboard/open_llm_leaderboard
한국어: huggingface.co/spaces/upstage/open-ko-llm-leaderboard | aihub.or.kr/leaderboard

Hugging Face — AI 모델의 GitHub

1 Hugging Face란?

AI 모델, 데이터셋, 데모 앱을 공유하는 오픈소스 플랫폼

"AI의 GitHub"이라고 불림(huggingface.co)

수십만 개의 사전학습 모델 제공

BERT, GPT, LLaMA 등 모두 여기서 다운로드

2 주요 기능

Models: 사전학습 모델 검색/다운로드

Datasets: 학습용 데이터셋 공유

Spaces: Gradio/Streamlit 데모 앱 호스팅

Transformers 라이브러리:

```
pip install transformers
```

→ 거의 모든 NLP/CV 모델을 3줄 코드로 사용 가능

3 코드 예시 — 감정 분석

```
from transformers import pipeline
classifier = pipeline(
  "sentiment-analysis",
  model="nlptown/bert-base-multilingual"
)
result = classifier( "이 영화 정말 좋았어!")
print(result) # [{'label':'5 stars','score':0.89}]
```

4 코드 예시 — 텍스트 생성

```
from transformers import pipeline
generator = pipeline( "text-generation",  model="gpt2")
result = generator(
  "인공지능의 미래는",
  max_length=50,
  num_return_sequences=1
)
print(result[0]   # ['generated_text'])
```

최신 트렌드 — AI Agent, 멀티모달, 추론 모델

1 AI Agent

LLM이 도구(Tool)를 사용하여
스스로 계획하고 실행하는 시스템

예: 웹 검색, 코드 실행,
파일 읽기/쓰기, API 호출

Claude Code, ChatGPT Code
Interpreter 등이 대표적

"AI가 생각만 하는 게 아니라
실제로 행동하는 단계"

2 멀티모달 AI

텍스트, 이미지, 음성, 영상을 통합
처리하는 AI

GPT-4V: 이미지 입력 가능
Gemini: 텍스트+이미지+영상
CLIP: 텍스트-이미지 연결
DALL-E, Stable Diffusion:
  텍스트 → 이미지 생성

미디어 연구에서의 의미:
  뉴스 영상의 텍스트+이미지를
  동시에 분석 가능

3 추론 모델 (o1, o3)

OpenAI o1, o3 시리즈

기존 GPT: 빠른 직관적 응답
추론 모델: 깊이 생각한 후 응답

Chain of Thought를 내재화
"생각하는 시간"을 가진 뒤 답변

수학, 과학, 코딩 등 복잡한 추론 과제에서
인간 전문가 수준 도달

Test-time Compute:
  추론 시 더 많은 연산을
  사용할수록 성능 향상